

Analisi comparativa delle capacità linguistiche e decodificative degli LLM: cifrari a sostituzione vs conlang



Studio empirico sulle prestazioni di decodifica e generazione in condizioni di alterazione linguistica non convenzionale e a basse risorse.

Domanda di ricerca:


Come si comporta un LLM di fronte a due differenti tipologie di alterazione linguistica non standard? Nello specifico, il modello gestisce meglio una codifica puramente meccanica (cifrario a sostituzione) oppure una lingua artificiale con strutture grammaticali e lessicali proprie (Trigedasleng)? Che tipo di ragionamento applica per la decodifica e la generazione? All'aumentare della complessità del testo, il modello rimane coerente o tende ad appiattirsi verso le lingue originali?

Obiettivi:

- Ingegnerizzazione di una Pipeline di Dati in python
- Estrazione e analisi delle metriche linguistiche
- Valutazione quantitativa dell'accuratezza di decodifica e della correttezza di generazione creativa in modalità zero-shot
- Analisi qualitativa degli errori

Cifrario a sostituzione meccanica

Elaborazione deterministica carattere per carattere,
strutturato sulla lingua italiana



Trigedasleng (The 100)

Conlang creola a basse risorse, derivata dall'inglese



Metodologia:

- Ambiente di sviluppo e Python Engineering (Google Colab)

Utilizzo dell'IA come supporto per la stesura di codici e script di automazione. Utilizzo dell'ambiente cloud Google Colab per il testing e l'esecuzione di codici Python, con focus sulla generazione di **output grafici**.

- Debugging & Refactoring

Risoluzione delle eccezioni di esecuzione "**IndentationError**", passaggio ad un'architettura di codice di tipo "**flat**".

- Strutturazione del dataset espanso

Accoglimento del feedback del docente: espansione del campione da **N = 3** a **N = 15** frasi per garantire affidabilità statistica. Campionamento stratificato.

- Protocollo sperimentale blindato

Isolamento del contesto: fresh chat & **zero-shot prompting**.

Architettura del Codice e Data Pipeline su Google Colab:

- Automazione del Cifrario Segreto:

Implementazione di uno script dizionario in Python (`cifrario = {'a':'д', 'b':'б', ...}`). Funzione `def` deterministica `f:(c) → (c')` basata sul metodo `.get()` per la sostituzione automatica dei grafemi.

- Ottimizzazione Script e Refactoring:

Risoluzione delle eccezioni di sistema (`IndentationError`) riscontrate nelle prime fasi su Google Colab.

Semplificazione dell'architettura: eliminazione dei cicli `for` e spaziature extra in favore di uno script piatto e lineare, utilizzo di `List Comprehension`.

- Dataset Trigedasleng:

Utilizzo IA → come gestisce i vuoti linguistici? Termini creoli/allucinazioni (frutto → fru), semplificazione semantica (mare → bluwoda), regressione verso l'inglese (mosaico → mosaik).

- Inserimento dati nel notebook:

Strutturazione dei dati in liste di dizionari Python (`dataset = [...]`).


Analisi del dataset:

- Tokenizzazione:


Utilizzo del modulo `re` tramite la funzione `re.sub()`, utilizzo del metodo `split()`.

- Metriche Linguistiche estratte e Output grafico (librerie `Matplotlib` e `NumPy`):

Dataset iniziale:



Dataset espanso $N = 15$:



- Evidenze empiriche emersi dai dati:

Italiano vs Cifrario: Sovrapposizione morfologica perfetta 1:1.

Italiano vs Trigedasleng: Evidente compressione strutturale. Nelle frasi complesse si passa da 21 parole (Italiano) a 15 parole (Trigedasleng), con una lunghezza media del token di sole 3.9 lettere contro 5.8 dell'italiano.

Esperimento 1

Test Quantitativo: Decodifica
Cifrario a sostituzione Meccanica

Ambiente e Protocollo: Test di
Crittanalisi senza chiave di lettura.
Fresh Chat (no bias di contesto) +
Zero-Shot Prompting su N=15 frasi
cifrate.

- Esito Quantitativo:

Tasso di Accuratezza: 100% (15/15 frasi ricostruite perfettamente in italiano).

- Fenomeni Rilevati & Crittanalisi dell'LLM:

Riconoscimento dei pattern. Flessibilità cognitiva e gestione delle Collisioni di Mapping: Il cifrario presentava ambiguità e sovrapposizioni:

La lettera **и** rappresentava sia il contoide occlusivo velare sonoro /G/, sia il vocoide anteriore alto non labializzato /I/.

Superamento delle anomalie e dei refusi: il modello ha decodificato correttamente anche refusi di cifratura (es. **губбио** al posto di **дуббио** nella frase 12).

- Implicazione Scientifica:

LLM non opera come un esecutore algoritmico lettera-per-lettera, ma applica un'inferenza contestuale e probabilistica sul contesto frasale. Sfrutta la probabilità sequenziale dei token in italiano per superare le collisioni di cifratura e intuire la parola corretta.

Esperimento 2

Test Quantitativo: Traduzione
Trigedasleng & Tassonomia degli
Errori

Ambiente e Protocollo: Fresh Chat
(no bias di contesto) + Zero-Shot
Prompting su N=15 frasi in
Trigedasleng.

- Esito Quantitativo:

Tasso di Accuratezza: 80% (Comprensione del senso globale corretta, ma con anomalie e deviazioni sistematiche rispetto al corpus canonico).

- Tassonomia e Classificazione degli errori dell'LLM:

Identificate discrepanze fonetiche e strutturali:

Categoria di Errore	Esempi rilevati nel Test	Spiegazione Linguistica & Limiti LLM
Calchi	fru (fruit), buke (book), skool (school)	L'IA semplifica l'ortografia anziché attingere al vocabolario canonico della lingua creola.
Neologismi / Allucinazioni	steidemon (per 'tutti/la gente'), hon year op (anniversario)	Invenzione di costrutti non attestati nel corpus ufficiale di David J. Peterson.
Errate strutture sintattiche	uso di rid op per 'leggere'	Trasposizione letterale dei phrasal verbs inglesi (read up) mancato utilizzo dei verbi appartenenti al corpus(luk in / get in).

- Evidenze sui limiti dell'LLM:

La scarsità di dati di addestramento (low-resource training data) sul Trigedasleng costringe il modello a "compensare" tramite la lingua madre (l'inglese), generando allucinazioni e calchi grammaticalmente scorretti.

Esperimento 3

Generazione creativa

Ambiente e Protocollo: Fresh Chat
(no bias di contesto) + Zero-Shot
Prompting

Compito 1: Generazione creativa in Cifrario a sostituzione

Richiesta: Produrre un breve testo di senso compiuto direttamente con i caratteri del cifrario.

Esito: Collasso cognitivo. L' LLM produce sequenze di caratteri prive di senso o si appiattisce verso una semplice traslitterazione fonetica in alfabeto cirillico (regressione al pattern più probabile nel dataset). Allucinazioni ortografiche: anche nella semplice traslitterazione commette errori e confonde i grafemi.

Causa Tecnica: Il motore di tokenizzazione (BPE) raggruppa i caratteri in token sub-word. L'LLM non ragiona naturalmente "carattere per carattere" durante la fase di generazione dell'output, non può dunque "pensare" direttamente in un cifrario arbitrario.

Ил **пикколо** и**ит**то иио**ка** мольто фэличе
нэл гиардино ди **и**аса, м**ент**ре ил соле
скалда тутта ла суа пелличча соффиче,
аскольтандо и румори делла натура ин
торно а луи, **и се** м**э**глия ди иочи.



Allucinazione morfologica senza senso

"Il **piccolo** g**it**to [gatto?] gioca molto felice nel
diardino [giardino] di **i**asa [casa], mentre il
sole scalda tutta la sua pelliccia soffice,
ascoltando i rumori della natura in torno a
lui, **e se** m**edliq** [si sceglie?] di iochi [giochi]."

Compito 2: Generazione creativa in Trigedasleng

Richiesta: Produrre un breve testo originale e di senso compiuto nella conlang.

Esito: Errori grammaticali e calchi, allucinazioni sintattiche, plagio strutturale e collage memetico.

Causa tecnica: assenza di competenza linguistica generativa. Aniché applicare regole grammaticali e sintattiche per creare nuove frasi, l' LLM ha assemblato frammenti di citazioni famose memorizzate dalla serie TV "The 100".

"Jus drein, gona! Klir op, frag em gada. Oso laik trikru, oso ste yuj. Heda bi op, chof noda, kom daun in blada. Wonkru kom hir, nou mou gonplei, jus klir klin, gonplei stoda."

"Sangue cola, guerriero! Pulisci in alto, uccidi lui/lei raccoglitore. Noi siamo Trikru [popolo degli alberi], noi siamo forti. Il Comandante [sia su], ringrazia/taglia un altro, da giù in [fratello?]. Wonkru vieni qui, niente più battaglia, sangue [usato erroneamente per "solo"] pulito completamente, la battaglia inizia."

Discussione critica - Come "ragionano" realmente gli LLM?

- Sintesi comparativa dei 3 esperimenti:

Esperimento	Task	Esito LLM	Meccanismo Sottostante
1	Decodifica Cifrario	100% Successo	Inferenza probabilistica basata sul contesto semantico nella lingua italiana
2	Traduzione Trigedasleng	80% Parziale	Allucinazioni e calchi sull'inglese, causa Low-Resource Data
3	Generazione Creativa	0% Fallimento	Collasso della Tokenizzazione / Collage memetico

- Ragionamento emergente vs. Memorizzazione statistica

I Large Language Models non sono esecutori logico-simbolici: non applicano "regole" come farebbe uno script Python. Il presunto "ragionamento" è un'illusione: un calcolo ad alta dimensione di probabilità condizionata che funziona brillantemente quando guidato dal contesto (decodifica), ma se costretto ad operare senza vincoli semantici di supporto (generazione creativa).

Conclusioni:

- Risposta alla domanda di ricerca iniziale:

Gli LLM non operano come esecutori algoritmico-simbolici dotati di vera comprensione delle regole grammaticali o crittografiche, ma agiscono come motori di inferenza statistico-probabilistica guidati dal contesto semantico. Nel complesso, il modello riesce a gestire opportunamente una richiesta di traduzione/decodifica, ma fallisce in entrambe le lingue nel tentativo di generare da zero un testo di senso compiuto.

- Sintesi delle scoperte empiriche:

- I. Punti di forza: resilienza contestuale. Eccellente capacità di ricostruzione semantica zero-shot in presenza di codici deterministici, anche di fronte a collisioni di mapping di caratteri.
- II. Punti di debolezza: vincoli architetturali. Collasso della tokenizzazione nei compiti di generazione carattere-per-carattere; tendenza a produrre allucinazioni/calchi e plagi strutturali su lingue a basse risorse.

- Impatto metodologico dell' ampliamento del Dataset (N=15):

L' espansione del campione su tre livelli di complessità frasale ha confermato la validità statistica dei risultati: la decodifica del cifrario rimane perfetta su qualsiasi lunghezza grazie allo sfruttamento del contesto semantico. L' allucinazione e la compressione morfologica del Trigedasleng si sono rivelate deviazioni strutturali e sistematiche.

- Implicazioni per la linguistica computazionale e sviluppi futuri:

1. Necessità di superare la tokenizzazione sub-word classica per compiti a livello di singolo carattere.
2. Importanza di integrare modelli neuro-simbolici per coniugare l' inferenza probabilistica degli LLM con la precisione logica delle regole matematiche e crittografiche.

Grazie per l'attenzione.